

Mapeamento Geológico via CNN Integrando Sensoriamento Remoto e Geoquímica: adaptação metodológica e perspectivas de aplicação em áreas vegetadas

Nome do(a) autor(a)

Bacharelado em Geologia

11 de novembro de 2025

1 Introdução (Contexto e motivação)

O mapeamento geológico desempenha papel fundamental na compreensão da estrutura e da evolução da crosta terrestre, servindo de base para estudos de prospecção mineral, geotecnia, geodinâmica e planejamento territorial. Em regiões recobertas por vegetação densa ou de difícil acesso, essa atividade enfrenta limitações consideráveis, sobretudo devido à escassez de afloramentos e às restrições impostas pelos métodos convencionais de observação direta.

Nas últimas décadas, os avanços nas tecnologias de sensoriamento remoto e nas técnicas de aprendizado de máquina transformaram a aquisição e a interpretação de dados geológicos. O uso combinado de imagens multiespectrais e hiperespectrais com levantamentos geoquímicos possibilita uma análise integrada das propriedades físicas e químicas das rochas. Entretanto, os classificadores tradicionais, como *Random Forest* e *Support Vector Machine*, ainda apresentam restrições quanto à interpretação espacial dos dados, resultando no chamado “efeito sal e pimenta” em mapas litológicos, caracterizado por classificações pontuais e pouco coerentes espacialmente.

Diante desse contexto, o artigo de Pan, Zuo e Wang (2023) propõe uma abordagem que combina dados multiespectrais e geoquímicos em um modelo baseado em redes neurais convolucionais (CNNs). Essa metodologia busca superar as limitações dos classificadores convencionais ao incorporar a correlação espacial e espectral entre as variáveis analisadas, resultando em uma interpretação mais precisa e contínua das unidades geológicas.

O presente relatório examina a metodologia proposta no artigo e discute sua aplicabilidade em diferentes contextos de mapeamento, especialmente em áreas cobertas por

vegetação, enfatizando o potencial da integração entre dados geoquímicos e de sensoria-mento remoto aliados a técnicas de inteligência artificial para aprimorar a identificação e a delimitação de unidades litológicas.

2 Resumo do artigo base (Fundamentação teórica)

Objetivo. Pan, Zuo e Wang (2023) investigam se a integração de dados multiespectrais (ASTER, Sentinel-2A) e geoquímicos regionais — após fusão multiorigem — combinada a uma CNN baseada em janelas espaciais pode aumentar a acurácia e a coerência espacial do mapeamento litológico em áreas sob cobertura vegetal.

Dados. O estudo emprega: (i) imagens ASTER (30 m) e Sentinel-2A (10 m); (ii) 39 variáveis geoquímicas (elementos maiores e traço). Um mapa geológico serve de referência para rotular amostras e validar resultados.

Pré-processamento e fusão. A etapa central é a fusão *Gram-Schmidt* (GS), que transfere informação espacial de maior resolução (S2A, 10 m) para a resposta espectral ASTER (30 m), preservando assinaturas espectrais e realçando textura/linhas. Em seguida, procede-se à fusão multiorigem (decomposição por pirâmide de Laplace) entre o cubo espectral fundido e as camadas geoquímicas, gerando bandas geoquímicas de alta resolução compatíveis com a malha óptica.

Classificador. Utiliza-se uma CNN de 10 camadas inspirada na AlexNet, com três convoluções intercaladas por três *poolings*, duas camadas totalmente conectadas e saída *softmax*. A entrada são *patches* 21×21 empilhando bandas espectrais e variáveis geoquímicas, permitindo que o modelo aprenda contexto espacial (vizinhança) além da assinatura espectral.

Resultados. A acurácia global ($\sim 83\%$) supera a de um *Random Forest* ($\sim 78\%$) treinado com os mesmos insumos. A CNN reduz o efeito “sal e pimenta” e melhora a delimitação de unidades pequenas/heterogêneas. Os ganhos decorrem da captação de padrões espaciais e da resolução efetiva maior das camadas geoquímicas fundidas.

Limitações. (i) Defasagem temporal entre ASTER (2003) e S2A (2020); (ii) densidade irregular de amostras geoquímicas; (iii) semelhanças espectrais entre litologias adjacentes. Ainda assim, demonstra-se a viabilidade e vantagem da abordagem CNN + fusão multiorigem para ambientes vegetados.

Pontos de interesse para a adaptação. (1) Tamanho da janela espacial como hiperparâmetro crítico (controla a escala geológica capturada); (2) fusão de dados para ampliar poder discriminante quando há pobreza de afloramentos; (3) arquiteturas CNN como alternativa a classificadores por-pixel, diminuindo ruído e melhorando fronteiras.

Tabela 1: Síntese comparativa entre o artigo base e a proposta de adaptação.

Aspecto	Artigo original	Proposta do grupo
Problema estudado	Mapeamento litológico em área vegetada (Jilinbaolige, China).	Mapeamento litológico em área genérica com cobertura vegetal densa (escala regional).
Tipo de dados	ASTER (30 m) + Sentinel-2A (10 m); 39 elementos geoquímicos; mapa geológico de referência.	Sentinel-2 L2A + ASTER; geoquímica regional (maiores e traço); opcional: DEM, magnetometria, gamaespectrometria.
Método (adaptação?)	Fusão GS + fusão multiorigem (pirâmide de Laplace) + CNN (patch-based 21×21).	Repetir o pipeline, ajustando tamanho de <i>patch</i> , bandas e hiperparâmetros; considerar UNet/ResNet-34 se houver rótulos poligonais densos.
Limitações	Defasagem temporal, densidade geoquímica irregular, semelhança espectral.	Geoquímica rala, heterogeneidade radiométrica, classes desbalanceadas; custo computacional.
Resultados obtidos / esperados	Acurácia $\approx 83\%$; redução “sal e pimenta”; melhor identificação de unidades pequenas.	Acurácia $\geq 80\%$, kappa e F1 por classe elevadas; fronteiras mais contínuas; incerteza quantificada.

3 Proposta de aplicação/adaptação

Novo problema/área. Aplicar o método em região fortemente vegetada (escala 1:100 000–1:250 000), visando discriminar litologias em contexto de afloramento escasso e heterogeneidade estrutural.

Dados pretendidos.

- *Óptico:* Sentinel-2 L2A (10–20 m; bandas VNIR/SWIR; índices espectrais derivados).
- *Óptico complementar:* ASTER (VNIR/SWIR/TIR; 15/30/90 m).
- *Geoquímica regional:* elementos maiores e traço (ICP-MS/FRX) em malha regional; interpolação se necessário.
- *Base geológica:* mapa de referência (polígonos litológicos) para amostragem supervisionada e validação.
- *Opcionais (recomendados):* DEM (derivados geomorfológicos), magnetometria e gamaespectrometria.

Semelhanças e diferenças versus o artigo. Semelhanças: tipo de problema (área vegetada), dupla fonte (espectral + geoquímica), uso de CNN com janelas. Diferenças: disponibilidade/qualidade de geoquímica; possíveis novas co-variáveis (DEM, magnetometria); sistemas de referência e escala.

Aplicabilidade direta do método. O *pipeline* é aplicável com ajustes:

1. Pré-processamento (correção atmosférica, mosaico, registro, mascaramento de nuvens).
2. Fusão GS (S2A→ASTER) com preservação espectral.
3. Fusão multiorigem (pirâmide de Laplace) para refinar geoquímica à malha óptica.
4. Engenharia de atributos (índices espectrais; texturas GLCM; derivadas do DEM; filtros de lineamentos).
5. Amostragem supervisionada (*patches* centrados em polígonos bem mapeados; controle de desbalanceamento).
6. Treino da CNN (tamanho de *patch* otimizado; *data augmentation*; *class weights*/focal loss).
7. Inferência (deslizante/FCN) e pós-processamento (suavização morfológica/CRF).

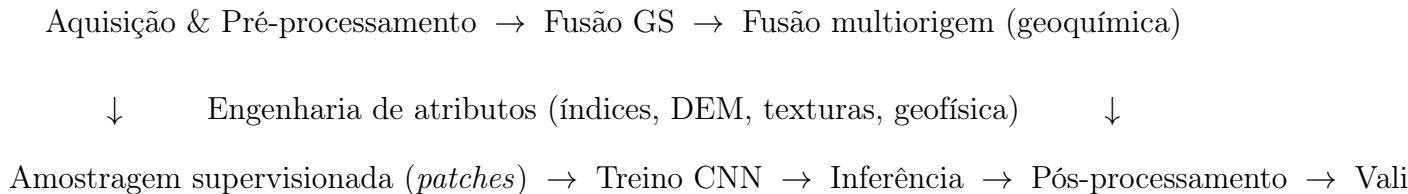
8. Validação (hold-out e validação cruzada espacial; métricas por classe; matriz de confusão; PR-curves para classes raras).
9. Quantificação de incerteza (*MC-Dropout/ensembles*) para guiar trabalho de campo.

Ajustes necessários. Hiperparâmetros: tamanho de *patch* (e.g., 15–31 px), *batch size*, *learning rate* e épocas; calibrar a escala à geologia local. Arquitetura: manter AlexNet-like para comparabilidade ou testar UNet/ResNet-34 se houver rótulos contínuos (segmentação semântica). Geoquímica rala: interpolação (IDW/krigagem) com máscara de suporte; avaliar incerteza de interpolação; ponderar por distância à amostra. Integração geofísica: empilhar bandas mag/gama normalizadas; padronizar por *z-score* após imputação simples (mediana). Desbalanceamento: *focal loss* ou *class weights*; amostragem estratificada em polígonos menores.

Avaliação do sucesso. Métricas principais: acurácia global, kappa, F1 por classe (macro/micro), e IoU (se segmentação). Estratégia: validação cruzada espacial (k-fold por blocos) para reduzir *leakage* espacial. Comparativos: RF/SVM por-pixel (baseline), CNN *patch*-based e (havendo rótulo denso) UNet/ResNet-Seg. Verificação de campo direcionada por incerteza (amostrar fronteiras com alta entropia/baixa confiança).

Recursos necessários. Computação: GPU única ($\geq 8\text{--}12$ GB) suficiente para *patches* 21×21 ; se UNet (512^2), ideal ≥ 16 GB; CPU para pré-processamento GDAL. Armazenamento: $\sim 50\text{--}200$ GB (mosaicos, cubos fundidos, *tiles* de treino). Tempo: pré-processamento (horas) e treino (horas a ~ 1 dia, conforme arquitetura/dados).

Fluxo (diagrama textual).



4 Desafios e limitações

Disponibilidade e qualidade de dados. Geoquímica pode ser esparsa e temporalmente não coeva com o óptico; ASTER/S2A têm datas distintas. *Mitigação*: interpolação com incerteza, máscaras de confiança e priorização de bandas/épocas contemporâneas; estratificar por estação seca/úmida.

Complexidade computacional. Treino de CNN com muitos canais aumenta memória e tempo. *Mitigação*: seleção de bandas (importância/permutação), PCA para compactação e modelos mais leves (ResNet-34 “slim”).

Semelhança espectral e mistura. Litologias próximas (e.g., arenitos vs. riolitos alterados) geram confusão de classes. *Mitigação*: índices diagnósticos (ferro/argilas),

TIR/ASTER, texturas, mag/gama e janelas maiores (sem perder detalhe).

Rotulagem imperfeita. Mapas de referência têm incerteza cartográfica; fronteiras difusas. *Mitigação:* *buffer* de fronteiras na amostragem, pós-suavização (CRF/morfologia), aprendizado ruidoso (*label smoothing*).

Generalização espacial. Risco de *overfitting* quando treino e teste são vizinhos. *Mitigação:* validação cruzada espacial, *hold-out* por blocos e avaliação por distância.

5 Resultados esperados e perspectivas

Resultados esperados.

- Acurácia $\geq 80\%$ com F1 macro superior ao *baseline* por-pixel; kappa elevado.
- Redução do “sal e pimenta” e fronteiras mais contínuas.
- Mapas de incerteza úteis para planejamento de campo.
- Melhor detecção de unidades pequenas/heterogêneas.

Contribuições. Protocolo reprodutível de fusão e CNN para áreas vegetadas; integração efetiva de geoquímica e óptico (e, quando disponível, geofísica).

Perspectivas. Piloto em subárea com validação de campo; extensão para arquiteturas de segmentação (UNet/DeepLab) quando houver rótulos densos; aprendizado auto-supervisionado/pré-treino multimodal; integração de *Vision Transformers* para contexto de longo alcance com dados mais abundantes.

6 Conclusão

A adaptação do método de Pan et al. mostra-se viável para mapeamento litológico em ambientes vegetados, desde que se ajuste a escala do *patch*, se mitigue desbalanceamento e se modele a incerteza decorrente da geoquímica esparsa e das defasagens temporais. A fusão multiorigem aliada a CNNs permite ganhos mensuráveis de acurácia e melhor continuidade espacial, posicionando o fluxo proposto como alternativa superior aos classificadores por-pixel em cenários de afloramento limitado.

7 Referências

Referências

- [1] PAN, T.; ZUO, R.; WANG, Z. Geological Mapping via Convolutional Neural Network Based on Remote Sensing and Geochemical Survey Data in Vegetation Coverage Areas.

IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, v. 16, p. 3485–3494, 2023.

- [2] POHL, C.; VAN GENDEREN, J. L. Multisensor image fusion in remote sensing: concepts, methods and applications. *International Journal of Remote Sensing*, v. 19, n. 5, p. 823–854, 1998.
- [3] RONNEBERGER, O.; FISCHER, P.; BROX, T. U-Net: Convolutional Networks for Biomedical Image Segmentation. In: *MICCAI*, 2015.
- [4] HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: *CVPR*, 2016.

Sugestões para a apresentação oral (10 min)

- **Contexto & problema (1 slide):** desafios em áreas vegetadas; efeito “sal e pimenta”.
- **Artigo & método (2 slides):** dados, fusões (GS + multiorigem), CNN *patch*-based.
- **Proposta (2 slides):** dados locais, ajustes (patch, bandas, métricas), diagrama do fluxo.
- **Desafios & mitigação (2 slides):** dados ralos, defasagem temporal, desbalanceamento.
- **Resultados esperados (1 slide):** métricas-alvo, mapas de incerteza, comparação com RF.
- **Conclusão (1 slide):** mensagem principal e próximos passos (piloto/validação de campo).